دانشگاه شهید چمران اهواز

دانشکده مهندسی

عنوان

تشخیص خونریزی مغزی در تصاویر سی‌تی‌اسکن با استفاده از ResNeXt101

گزارش پروژه کارشناسی

نگارنده: شقایق شوشتری

استاد راهنما: دکتر محمود فرخیان

بهمن 1399

چکیده

در این پروژه از یک مدل آموزش‌دیده برای تشخیص وجود خونریزی در هر برش سی‌تی‌اسکن سر استفاده شده است. هر برش، یک تصویر مقطعی از سی‌تی‌اسکن است. مدل انتخاب‌شده ResNeXt101 به همراه یک ماژول کوچک توجه کانالی به نام ECA است. تصاویر به شکل یکسان آماده‌سازی شده و سپس وارد شبکه می‌شوند. تمرکز گزارش بر خروجی Any مدل است که وجود یا نبود خونریزی را نشان می‌دهد.
ارزیابی نهایی شامل ۷۴,۹۵۰ برش است. دقت مدل ۹۵٫۲۲٪، حساسیت ۷۵٫۸۰٪ و امتیاز F1 برابر با ۸۱٫۷۱٪ برای خروجی Any گزارش شده است. نتایج نشان می‌دهند مدل عملکرد مناسبی در تشخیص خونریزی دارد، هرچند همچنان بخشی از تصاویر مثبت را تشخیص نمی‌دهد.

۱. پروژه چه کاری انجام می‌دهد

یک سی‌تی‌اسکن شامل تعداد زیادی برش است و هر برش مقطع متفاوتی از سر را نشان می‌دهد. در این پروژه، مدل هر بار یک برش را بررسی کرده و امتیازی برای وجود خونریزی تولید می‌کند. برای این تصمیم از برش‌های مجاور استفاده نمی‌شود.
مسئله اصلی، طبقه‌بندی تصویر است؛ یعنی قرار دادن هر تصویر در یک گروه. در اینجا دو حالت مورد نظر، وجود خونریزی و نبود خونریزی هستند. از مدل خواسته نمی‌شود مرز ناحیه خونریزی را رسم کند، حجم آن را اندازه بگیرد یا درمانی پیشنهاد دهد.
در پروژه از یادگیری انتقالی استفاده شده است. یعنی به‌جای شروع آموزش با وزن‌های تصادفی، از مدلی استفاده می‌شود که قبلاً الگوهای مفیدی از تصاویر را یاد گرفته است. این الگوها نقطه شروع مناسبی برای سازگار کردن شبکه با تصاویر سی‌تی‌اسکن هستند؛ اما به این معنی نیست که مدل اولیه از قبل خونریزی را تشخیص می‌داده است.
کار در سه مرحله اصلی انجام می‌شود: آماده‌سازی تصاویر، دریافت پیش‌بینی شبکه و مقایسه پیش‌بینی با برچسب واقعی. سوال اصلی این است که مدل انتخاب‌شده تا چه اندازه برش‌های مثبت را تشخیص می‌دهد. همچنین بررسی می‌شود که آیا دقت کلی بالا به‌تنهایی تصویر کاملی از عملکرد مدل ارائه می‌دهد یا خیر.
محدوده پروژه شامل یک شبکه CNN است. کاهش ویژگی، طبقه‌بند درختی جداگانه، شبکه بازگشتی یا مقایسه چند معماری مختلف در این پروژه انجام نشده است. ResNeXt101 در تمام مراحل به‌عنوان شبکه اصلی استفاده می‌شود.

۲. داده‌ها و آماده‌سازی تصاویر

تصاویر و برچسب‌ها

تصاویر از مجموعه داده RSNA 2019 مربوط به خونریزی داخل جمجمه گرفته شده‌اند. هر تصویر دارای برچسب ثبت شده است. برای برچسب Any ، مقدار ۱ به معنی وجود خونریزی و مقدار ۰ به معنی نبود خونریزی است. مجموعه تست استفاده شده شامل تعداد برش‌های زیر است. [1, 2]

جدول ۱. برش‌های مجموعه تست در ارزیابی CNN.

Test group	Slices
Hemorrhage absent	64,392
Hemorrhage present	10,558
Total	74,950

بیشتر تصاویر مجموعه تست منفی هستند. این موضوع مهم است، زیرا برنامه‌ای که همیشه «بدون خونریزی» پیش بینی کند نیز در حدود ۸۵/۹۱٪ این مجموعه پاسخ درست خواهد داشت. بنابراین علاوه بر دقت کلی، باید بررسی شود که مدل چه تعداد از تصاویر مثبت را پیدا می‌کند.
داده‌ها به سه بخش آموزش، اعتبارسنجی و تست تقسیم شده‌اند. داده‌های آموزش برای یادگیری وزن‌های مدل، داده‌های اعتبارسنجی برای بررسی انتخاب‌ها در زمان توسعه و داده‌های تست برای ارزیابی نهایی استفاده می‌شوند. کد تقسیم داده‌ها تصاویر را بر اساس سری تصویربرداری گروه‌بندی می‌کند. همچنین بهتر است هم پوشانی بیماران بررسی شود، زیرا ممکن است یک بیمار چند سری تصویربرداری داشته باشد.

آماده‌سازی یک برش برای شبکه

تصاویر با فرمت DICOM ذخیره شده‌اند. فایل DICOM علاوه بر تصویر، اطلاعات لازم برای خواندن صحیح مقادیر پیکسل را نیز دارد. بارگذار داده از این اطلاعات برای تبدیل مقادیر ذخیره‌شده به واحد هانسفیلد (Hounsfield Unit)، یعنی مقیاس شدت مورد استفاده در تصاویر CT، استفاده می‌کند.
سپس کد سه نمای مختلف از همان برش را با محدوده‌های شدت متفاوت ایجاد می‌کند: brain، subdural و soft tissue. این فرایند windowing نام دارد و شبیه انتخاب تنظیمات کنتراست مختلف برای بهتر دیده شدن جزئیات است. این سه تصویر، سه نمای متفاوت از یک برش هستند و سه اسکن جداگانه نیستند.
سه نما به عنوان سه کانال تصویر ورودی روی هم قرار می‌گیرند. تصویر به اندازه ۲۵۶×۲۵۶ پیکسل تغییر اندازه داده می‌شود و سپس با استفاده از میانگین و انحراف معیار کانال‌ها که در کد مشخص شده‌اند نرمال سازی می‌شود. نرمال سازی باعث می‌شود مقادیر ورودی در مقیاسی یکسان قرار گیرند.

در زمان آموزش، تغییرات تصادفی کوچک روی تصاویر باعث ایجاد تنوع بیشتر می‌شوند. تصاویر تست بدون تغییرات تصادفی و با پردازش ثابت آماده می‌شوند. ثابت ماندن این فرایند اهمیت زیادی دارد، زیرا تغییر ترتیب کانال‌ها، اندازه تصویر یا نحوه پردازش شدت می‌تواند رفتار مدل را تغییر دهد.

۳. نحوه عملکرد مدل

یادگیری الگوهای مفید تصویر

ResNeXt101 یک شبکه عصبی کانولوشنی است. شبکه کانولوشنی با استفاده از فیلترهای یادگرفته شده، الگوهای موجود در تصویر را پیدا می‌کند. لایه‌های ابتدایی می‌توانند الگوهای ساده‌تری مانند لبه‌ها و تغییرات شدت را تشخیص دهند و لایه‌های بعدی این اطلاعات را به ویژگی‌های پیچیده‌تر تبدیل می‌کنند. ویژگی در اینجا یک توصیف عددی است که مدل از تصویر یاد می‌گیرد و لزوماً نام پزشکی جداگانه‌ای ندارد.
در پیاده‌سازی انتخاب‌شده از backbone ازپیش‌آموزش‌دیده resnext101_32x8d_wsl استفاده شده است.
همچنین ماژول ECA وجود دارد که اهمیت کانال‌های ویژگی را تنظیم می‌کند. این کانال‌های داخلی، الگوهای یادگرفته‌شده شبکه را توصیف می‌کنند و با سه کانال تصویر ورودی متفاوت هستند. خروجی ECA پیش از مرحله نهایی طبقه‌بندی به ویژگی‌های اصلی اضافه می‌شود.
سپس شبکه با میانگین‌گیری از نقشه‌های ویژگی، خلاصه‌ای از هر برش را به شکل یک بردار شامل ۲۰۴۸ عدد تولید می‌کند. این اعداد ویژگی‌های یادگرفته‌شده تصویر هستند و به معنی ۲۰۴۸ پیکسل یا ۲۰۴۸ نوع بیماری نیستند. در پایان، یک لایه خطی این بردار را به شش امتیاز خام تبدیل می‌کند.

استفاده از خروجی Any

مدل موجود پنج خروجی برای انواع خونریزی و یک خروجی با نام Any دارد. در این گزارش از Any برای پاسخ به سؤال ساده‌تر «آیا خونریزی وجود دارد؟» استفاده شده است. سایر خروجی‌ها برای سازگاری مدل با وزن‌های آموزش‌دیده آن حفظ شده‌اند. بنابراین این مدل، یک مدل جدید با تنها یک خروجی نیست.
امتیاز خام مدل logit نام دارد. تابع sigmoid آن را به مقداری بین صفر و یک تبدیل می‌کند. سپس با استفاده از یک آستانه، تصمیم نهایی بله یا خیر گرفته می‌شود. مقدار این آستانه اهمیت دارد، زیرا تغییر آن می‌تواند تعداد موارد تشخیص‌داده‌شده و هشدارهای اشتباه را تغییر دهد.

آموزش و اجرای پیاده‌سازی

کد با Python و PyTorch نوشته شده است. تنظیمات قابل مشاهده آموزش شامل batchهای ۳۲ تصویری، بهینه‌ساز Adam و نرخ یادگیری ۰٫۰۰۰۰۱ است. batch گروهی از تصاویر است که در یک مرحله آموزش پردازش می‌شوند. تابع هزینه BCEWithLogitsLoss اختلاف بین خروجی‌های خام و برچسب‌های واقعی را اندازه‌گیری می‌کند تا وزن‌های مدل به‌روزرسانی شوند.

در مرحله ارزیابی، checkpoint مدل ECA آموزش‌دیده بارگذاری و روی مجموعه تست اجرا می‌شود. checkpoint وزن‌های یادگرفته‌شده مدل را ذخیره می‌کند و هر epoch یک بار عبور کامل از داده‌های آموزش است. برای بازتولید همان ارزیابی باید از checkpoint، تقسیم‌بندی داده‌ها و تنظیمات پیش‌پردازش متناظر استفاده شود. نتایج زیر خلاصه ارزیابی خروجی Any روی مجموعه تست هستند.

۴. نتایج و جمع‌بندی

تفسیر نتایج

ارزیابی تست، مقادیر زیر را برای خروجی Any روی ۷۴,۹۵۰ برش گزارش می‌کند. Sensitivity ،Precision و F1 عملکرد مدل روی کلاس مثبت خونریزی را توصیف می‌کنند.

جدول ۲. نتایج تست CNN.

Measure	Value
Accuracy	95.22%
Precision	88.62%
Sensitivity	75.80%
F1 score	81.71%
AUC	0.9689

برای مثال، حساسیت ۷۵٫۸۰٪ یعنی تقریباً ۷۶ مورد از هر ۱۰۰ برش مثبت تشخیص داده می‌شوند و حدود ۲۴ مورد از دست می‌روند. Precision سؤال متفاوتی را پاسخ می‌دهد: از هر ۱۰۰ پیش‌بینی مثبت، تقریباً ۸۹ مورد درست هستند. این اعداد فقط برای توضیح نسبت‌ها هستند و تعداد دقیق تصاویر تست یا بیماران را نشان نمی‌دهند. Accuracy تمام تصمیم‌های صحیح را می‌شمارد و F1 ترکیبی از Precision و Sensitivity است. در ارزیابی، logit خام با مقدار ۰٫۵ مقایسه شده است که تقریباً معادل آستانه احتمال ۰٫۶۲۲۵ پس از sigmoid است. تغییر این قانون تصمیم‌گیری نیازمند ارزیابی مجدد است. AUC توانایی مدل در رتبه‌بندی امتیازها را اندازه می‌گیرد و درصد تصمیم‌های صحیح نیست.

نتیجه چه چیزی نشان می‌دهد

CNN انتخاب‌شده در این آزمایش جداسازی مناسبی بین برش‌های مثبت و منفی ایجاد می‌کند. با این حال، دقت بالا به این معنی نیست که تمام موارد خونریزی تشخیص داده می‌شوند. حساسیت پایین‌تر یکی از محدودیت‌های مهم مدل است. همچنین مدل هر برش را به‌صورت مستقل پردازش می‌کند و عملکرد آن روی مجموعه‌داده مستقل از بیمارستانی دیگر بررسی نشده است.

برای بازتولید ارزیابی باید از همان checkpoint، تقسیم‌بندی مجموعه‌داده و تنظیمات پیش‌پردازش استفاده شود. جداسازی بیماران بین بخش‌های داده نیز باید بررسی شود. ResNeXt101 از نظر محاسباتی مدل نسبتاً سنگینی است.

منابع

[1] Rahimi, P. Detection and Classification of Brain Hemorrhage in CT Images Using Deep Learning. Shahid Chamran University of Ahvaz., این مطالعه گسترده‌تر از داده‌های RSNA Intracranial Hemorrhage Detection، 2019 استفاده می‌کند.

[2] پیاده‌سازی پروژه: Shaghayegh_Shushtari_Bachelor_Project.ipynb.

[3] Xie, S., et al. Aggregated Residual Transformations for Deep Neural Networks. CVPR, 2017.

Wang, Q., et al. ECA-Net: Efficient Channel Attention for Deep Convolutional Neural Networks. CVPR, 2020.